ПРАКТИЧЕСКИ ГАЙД / 01

Локален AI за код в LM Studio и VS Code

Настройка с модел за бюджет до **12 GB VRAM**. Основен вариант: **Qwen3.5 9B + LM Studio + Cline**. Включени са Continue, Bionic, Ollama и решенията на срещнатите грешки.

Версия 1.0 • 23 октомври 2026 г. • Език: български

Кой компонент какво прави

Компонент	Роля
Qwen3.5 9B	Моделът, който разбира заявките и генерира код.
LM Studio	Зарежда модела локално и го предоставя през API.
Cline / Continue	Свързват модела с проекта във VS Code.
Bionic	Отделно приложение с вграден агент за код и файлове.

Избор на модел

Модел	Размер на пакета*	Практическа употреба
Qwen3.5 9B	Около 6.6-7.6 GB	Начален избор за чат и агентни задачи.
Qwen2.5-Coder 14B Q4	Около 9 GB	Алтернатива, специализирана за код; по-малко място остава за контекст.

* Ориентири от каталога на Ollama [1, 2]. GGUF файловете в LM Studio зависят от издателя и варианта. Размерът за изтегляне не е общата използвана VRAM.

Работна отправна точка

Избери GGUF вариант **Q4_K_M**, започни с **8192** токена и тествай **16384**, след това **32768** според свободната памет. Побиране изцяло в 12 GB не се гарантира само по името на модела.

За настройване на LM Studio виж стр. 2; Cline - стр. 3; Continue - стр. 4; контекст - стр. 5; грешки - стр. 6; Bionic и Ollama - стр. 7.

ПРАКТИЧЕСКИ ГАЙД / 02

LM Studio: модел и сървър

Следните стъпки използват имената от показания в разговора интерфейс. В други версии **Library** може да се казва **My Models**, а **Model Server** - **Developer**.

01. Инсталирай стандартния **LM Studio** от lmstudio.ai/download. Bionic е отделно приложение.

02. Отвори **Model Search** (или Discover). Намери **Qwen3.5 9B**, избери GGUF **Q4_K_M** и изтегли избрания вариант.

03. В **Library** намери модела. Отвори настройките му с иконата за конфигурация и прегледай параметрите за зареждане. В документацията това са per-model defaults. [3]

Настройка	Начална стойност / действие
Context Length	8192 за първа проверка; 16384 при нужда от повече контекст.
GPU Offload	Зареди възможно най-много от модела на GPU, като следиш оценката за паметта.
Flash Attention	Може да намали паметта и да ускори изпълнението при поддържан runtime. [4]

04. Зареди модела с **Load**. След промяна на параметрите за зареждане използвай **Reload** или **Unload → Load**. [3]

05. Отвори **Settings → Developer → Developer Mode: ON**, ако напредналите настройки са скрити. После затвори Settings. [5]

06. В главната лява лента натисни **Model Server**, непосредствено под **Chat**. Включи **Start Server**; статус Running означава, че сървърът работи. [6]

Адрес на локалния сървър

http://localhost:1234
Това е стандартният адрес на същия компютър. Ако си променил порта, използвай своя порт и във VS Code. Поддържай модела зареден или включено автоматично зареждане при заявка.

Алтернатива през терминал: `lms server start`. За обичайния графичен процес използвай бутона в Model Server. [6]

ПРАКТИЧЕСКИ ГАЙД / 03

VS Code + Cline

Cline е вариантът за задачи, при които моделът чете проект, редактира файлове и изпълнява команди през инструменти.

01. Отвори папката на проекта във VS Code и инсталирай разширението **Cline**.

02. Отвори **Cline → Settings → API Configuration**. Задай следните стойности. [7]

Поле	Стойност
API Provider	**LM Studio**
Use custom base URL	Остави изключено при стандартния локален адрес.
Base URL, ако е включено	`http://localhost:1234`
Model	Избери точния зареден идентификатор, например **qwen/qwen3.5-9b**.
Context Window	При показания интерфейс се прочита от LM Studio; виж стр. 5.

03. В **Settings → Features** включи **Use Compact Prompt**, както препоръчва Cline за локално изпълнение. Това намалява обема на системните инструкции. [7]

04. Запази настройките и започни с кратка задача. При отделни настройки за режимите Plan и Act провери избора на локален модел и за двата.

Първа задача за проверка

Примерна заявка

Прегледай структурата на този проект. Посочи стартовите файлове и обясни как се стартира приложението. След това намери обработката на грешки в посочения модул и предложи конкретна поправка.

За по-голяма промяна посочи целта, конкретните файлове и какъв резултат очакваш. След редакцията прегледай diff-а и резултата от подходяща проверка. Това прави оценката на локалния модел по-практична от един общ въпрос.

Как изглежда успешната връзка

LM Studio получава заявката, моделът започва да генерира, а отговорът се появява в Cline. Ако виждаш грешка за endpoint, провери адреса на стр. 6. Ако няма достатъчно място за инструкциите и файловете, увеличи контекста по стр. 5.

ПРАКТИЧЕСКИ ГАЙД / 04

VS Code + Continue

Continue е подходящ за чат, редактиране на код и отделно конфигурирано дописване с Tab. Той поддържа директно provider **lmstudio**. [8, 9]

01. Инсталирай **Continue** във VS Code. Отвори локалната му конфигурация **config.yaml** през настройките на разширението.

02. Добави или адаптирай следния запис. Ако вече имаш конфигурация, добави модела под съществуващия списък **models**. [8, 9]

```
name: Local coding
version: 1.0.0
schema: v1

models:
  - name: Qwen local
    provider: lmstudio
    model: qwen/qwen3.5-9b
    apiBase: http://localhost:1234/v1
    roles:
      - chat
      - edit
      - apply
    defaultCompletionOptions:
      contextLength: 16384
      maxTokens: 2048
```

Използвай **точния Model ID**, който връща твоят сървър. Примерът е съобразен с видимия в разговора идентификатор. Провери го и през `GET /v1/models`. [10]

Съгласувай контекста

contextLength: 16384 в Continue е клиентска настройка. Зареди модела в LM Studio с подходящ контекст, например същите **16384**. Промяната само в YAML не увеличава вече заделения контекст на сървъра. [3, 9]

Дописване с Tab

Това е отделната роля **autocomplete**. За нея е подходящ модел, обучен за fill-in-the-middle (FIM), например малък вариант от Qwen2.5-Coder. Голям чат модел не е автоматично най-добрият избор за дописване. [11]

При 12 GB VRAM първо провери чата с един модел. Ако добавиш отделен модел за Tab, общата памет и превключването между моделите могат да повлияят на скоростта. Избери точния му Model ID и му задай роля **autocomplete**.

ПРАКТИЧЕСКИ ГАЙД / 05

Увеличаване на контекста

Контекстът включва инструкциите, разговора, подадения код и резултатите от инструменти. Оставя се място и за генерирания отговор; размерът на контекста не е равен на максималната дължина на отговора.

Случаят от разговора: Cline показва 8192

В показания прозорец полето **Context Window** е неактивно. Промяната започва от параметрите на модела в LM Studio, след което се обновява клиентът.

01. В **LM Studio → Library** намери **qwen/qwen3.5-9b** и отвори настройките му. Потърси секцията **Load Settings** или параметрите за зареждане. [3]

02. Задай **Context Length: 16384**. Запази настройката като подразбираща се за този модел, ако искаш да се запазва при следващи зареждания. [3]

03. Натисни **Reload** или **Unload → Load**. Новият контекст трябва да бъде приложен при зареждането. [3, 4]

04. Върни се в Cline, отвори настройките и избери модела отново. Ако стойността остане стара, изпълни **Ctrl+Shift+P → Developer: Reload Window** и провери пак.

Стойност	Практическо предназначение
8192 токена	Начална проверка на връзката и кратки задачи.
16384 токена	Следваща стъпка за повече инструкции и код.
32768 токена	Пробвай след измерване на паметта при 16K.
64K / 128K и повече	Изискват отделна оценка на паметта и реалната скорост.

Три различни числа

Поддържан максимум: пределът на модела.
Зареден контекст: реалната настройка в LM Studio.
Клиентски бюджет: стойността, с която Cline или Continue планира заявката.
Показан максимум от 128K не доказва, че моделът е зареден с 128K.

При 12 GB VRAM увеличавай постепенно и следи потреблението. Паметта за кеша и изчисленията се добавя към теглата. Ако се появи недостиг на памет или голямо забавяне, върни предишната работеща стойност. Това е практическа насока, а не гарантиран максимум за конкретна карта. [4]

ПРАКТИЧЕСКИ ГАЙД / 06

Грешки и бърза диагностика

Провери първо адреса, после идентификатора на модела и накрая параметрите за зареждане.

Unexpected endpoint or method

Срещнатата грешка беше **POST /api/v1/chat/completions**. За OpenAI-съвместимия chat endpoint правилният път е **POST /v1/chat/completions**. Допълнителното **/api** прави този конкретен път невалиден. [10]

Доставчик / клиент	Base URL
Cline → LM Studio	`http://localhost:1234`
Continue → LM Studio	`http://localhost:1234/v1`
OpenAI-съвместим клиент	`http://localhost:1234/v1`

Остави добавянето на `/chat/completions` на клиента. LM Studio има и отделни native REST endpoints под `/api/v1`, например за зареждане на модел; не ги смесвай с OpenAI-съвместимия адрес. [4, 10]

Провери списъка с модели

```
curl http://localhost:1234/v1/models
```

При стандартна конфигурация отговорът е JSON със списък от модели. Сравни полето **id** с избрания модел във VS Code. При включена автентикация подай и съответния LM Studio token. [10]

Симптом	Следваща проверка
Connection refused / няма връзка	Model Server е Running; адресът и портът съвпадат.
Моделът липсва или model not found	Провери изтеглянето, зареждането и точния Model ID.
Cline още показва 8192	Презареди модела, избери го отново и обнови VS Code.
Недостиг на памет	Намали контекста; освободи памет от други заредени модели.
Бавен отговор	Провери GPU offload, обема на контекста и употребата на RAM.
Агентът не извиква инструменти	Провери tool-use поддръжката и runtime-а; опитай кратка задача и Compact Prompt.

ПРАКТИЧЕСКИ ГАЙД / 07

Алтернативи: Bionic и Ollama

Основният гайд използва LM Studio + Cline. Следните варианти покриват останалите възможности, обсъдени в разговора.

Bionic: готов агент в отделно приложение

Bionic събира моделите и агентния интерфейс в отделно приложение. Може да работи с локални модели, облачни модели и модели на друго устройство. За изцяло локална работа избери **Local**. [12, 13]

Критерий	LM Studio + Cline	Bionic
Работна среда	Във VS Code	Отделно приложение
Свързване	Локален API + разширение	Модел и проект в приложението
Файлове и команди	Чрез Cline	Вградени агентни инструменти

За проект в Bionic: **New Project → Allow coding → Choose a folder → Create**. Избери корена на проекта и локален модел. Същата папка може да е отворена във VS Code, където преглеждаш направените промени. [12]

При един и същ модел, квантизация и контекст очаквай сходни изисквания към паметта. Това е практическо очакване; качеството и поведението зависят и от инструкциите и инструментите на агента.

Ollama: алтернативен локален сървър

След инсталиране и стартиране на Ollama можеш да използваш:

```
ollama pull qwen3.5:9b
ollama run qwen3.5:9b
ollama ps
```

В **ollama ps** колоната **PROCESSOR** показва разпределението CPU/GPU. Стойност **100% GPU** означава изцяло GPU зареждане. [14]

За официалното разширение **Ollama** във VS Code: инсталирай го от издателя Ollama, отвори Chat и избери модела от секцията Ollama. Актуалната документация посочва **VS Code 1.127+**; стандартният адрес е **http://127.0.0.1:11434**. [15]

В Cline при този вариант избери provider **Ollama**. За LM Studio запази provider **LM Studio** и порт 1234. Командите `ollama ...` се отнасят за Ollama, а `lms ...` - за LM Studio.

ПРАКТИЧЕСКИ ГАЙД / 08

Контролен списък и източници

Използвай този списък след първоначална настройка или след смяна на модел.

01. Моделът е изтеглен; записан е точният му Model ID.

02. Моделът е зареден с избрания Context Length.

03. Model Server работи на очаквания адрес и порт.

04. Provider и Base URL във VS Code съответстват на таблицата на стр. 6.

05. След промяна на контекста моделът е презареден и клиентът е обновен.

06. Кратка заявка работи; проверени са паметта и една малка задача по проекта.

Официални справки

[1] Qwen3.5 9B - Ollama

[2] Qwen2.5-Coder 14B - Ollama

[3] LM Studio - настройки по модел

[4] LM Studio - зареждане и параметри

[5] LM Studio - Developer Mode

[6] LM Studio - локален API сървър

[7] Cline - локални модели

[8] Continue - provider LM Studio

[9] Continue - справка за config.yaml

[10] LM Studio - OpenAI-съвместими endpoints

[11] Continue - autocomplete и FIM

[12] Bionic - първи проект

[13] Bionic - локални, облачни и remote модели

[14] Ollama - контекст и GPU offload

[15] Ollama - интеграция с VS Code

Съставено от настройките и решенията в разговора. Документацията е проверена към 23.10.2026 г. Препоръките за 12 GB VRAM са начални ориентири, без измерване на конкретния компютър. Имената на менютата могат да се различават между версии.